Reporte 1: Hábitos de estudio y calificación final

Saúl Ubaldo Rojas Vázquez

06/10/2026

1. Introducción

El conjunto *Student Performance and Study Habits* (Kaggle) describe a 1000 estudiantes mediante sus hábitos (horas de estudio, asistencia y sueño), su contexto (género, educación de los padres, acceso a internet, trabajo de medio tiempo y actividades extracurriculares), su calificación previa y su calificación final. Es un conjunto **sintético**, por lo que las conclusiones describen la estructura de los datos y no son evidencia causal.

El objetivo es de **alerta temprana**: anticipar la calificación final de un estudiante usando solo información disponible antes del examen final (sus hábitos y su calificación previa). Usamos Análisis Discriminante Lineal (LDA), que cumple un doble propósito: como clasificador, asigna a cada estudiante una calificación (A a F); como técnica descriptiva, identifica las combinaciones de variables que mejor separan las calificaciones. Buscamos responder: (1) ¿qué tan bien puede anticiparse la calificación final antes del examen?; (2) ¿qué características distinguen a los estudiantes de distintas calificaciones?; y (3) ¿entre qué calificaciones se equivoca el clasificador, es decir, qué tan grave es el error cuando ocurre?

2. Datos

La base tiene 12 variables, 0 valores faltantes y 0 registros duplicados (buscados ignorando `student_id`, que descartamos por ser solo un identificador).

Cuadro 1: Estadísticas descriptivas de las variables numéricas.

Variable	Mínimo	Q1	Mediana	Media	D.E.	Q3	Máximo
attendance_percent	54.8	78.80	85.2	85.09	9.27	91.90	100.0
final_exam_score	46.8	76.07	83.8	83.54	10.34	91.53	100.0
previous_grade	31.3	61.00	69.6	69.74	12.61	78.40	100.0
sleep_hours	3.2	5.90	6.8	6.80	1.20	7.60	10.0
study_time_hours	0.5	2.60	3.6	3.57	1.48	4.50	8.1

Las variables categóricas se distribuyen así: `gender` (Female 51 %, Male 49 %); `parental_education` (High School 36 %, Bachelors 31 %, Masters 18 %, None 10 %, PhD 5 %); `internet_access` (Yes 85 %, No 15 %); `extracurricular_activities` (Yes 57 %, No 43 %); `part_time_job` (No 68 %, Yes 32 %). La calificación final tiene la distribución A 28.4 %, B 35.4 %, C 26.1 %, D 8.9 %, F 1.2 %.

Fuga de información. `final_grade` es una discretización del examen final: sus rangos por categoría no se traslapan (A: 90 a 100; B: 80 a 89.9; C: 70 a 79.9; D: 60 a 69.9; F: 46.8 a 59.7). Usar `final_exam_score` como predictor daría una clasificación trivialmente perfecta y, además, contradice el objetivo de alerta temprana, pues el examen aún no ocurre al momento de predecir. Por ello **la excluimos**. Conservamos `previous_grade`, que se observa antes del periodo evaluado.

3. Metodología

LDA supone que, dentro de cada calificación k, el vector de predictores es normal multivariado con media μ_k y una **matriz de covarianzas común** Σ. Bajo ese supuesto, la regla de Bayes asigna cada estudiante a la clase con mayor función discriminante

$$\delta_k(x) = x^\top \Sigma^{-1}\mu_k - \tfrac{1}{2}\mu_k^\top \Sigma^{-1}\mu_k + \log \pi_k,$$

que es lineal en x. Elegimos LDA porque sus parámetros tienen interpretación directa y porque proyecta los datos en a lo más $K-1$ direcciones que resumen la separación entre clases.

Decisiones. (i) Usamos solo las cuatro variables numéricas, pues las categóricas son binarias o nominales y violan el supuesto de normalidad. (ii) Estandarizamos con la media y desviación del conjunto de **entrenamiento**, para que la información de prueba no influya en el ajuste; esto no cambia las clasificaciones de LDA, pero hace comparables los coeficientes. (iii) Estimamos π_k con las proporciones observadas. (iv) Dividimos los datos en 70 % entrenamiento y 30 % prueba, estratificando por calificación, con semilla 2026.

4. Implementación

Partición y estandarización.

```
set.seed(2026)
datos <- datos |> mutate(final_grade = factor(final_grade))
idx <- createDataPartition(datos$final_grade, p = 0.7, list = FALSE)

X_tr <- as.matrix(datos[idx, vars_num]);  y_tr <- datos$final_grade[idx]
X_te <- as.matrix(datos[-idx, vars_num]); y_te <- datos$final_grade[-idx]

medias <- colMeans(X_tr); desv <- apply(X_tr, 2, sd)
X_tr <- scale(X_tr, center = medias, scale = desv)
X_te <- scale(X_te, center = medias, scale = desv)
```

Estimadores. $\hat\pi_k = n_k/n$, $\hat\mu_k$ es la media de la clase k y $\hat\Sigma = \frac{1}{n-K}\sum_k \sum_{i\in k}(x_i-\hat\mu_k)(x_i-\hat\mu_k)^\top$.

```
K <- levels(y_tr)
pi_hat <- prop.table(table(y_tr))
mu_hat <- t(sapply(K, \(k) colMeans(X_tr[y_tr == k, ])))

Sigma_hat <- Reduce(`+`, lapply(K, \(k) {
  Xc <- scale(X_tr[y_tr == k, ], center = mu_hat[k, ], scale = FALSE)
  crossprod(Xc)
})) / (nrow(X_tr) - length(K))
```

Cuadro 2: Probabilidades a priori y medias por clase (variables estandarizadas).

	$\hat\pi_k$	study_time_hours	attendance_percent	sleep_hours	previous_grade
A	0.28	0.78	0.32	0.16	0.48
B	0.35	-0.03	-0.02	0.05	0.07
C	0.26	-0.46	-0.14	-0.12	-0.40
D	0.09	-0.92	-0.37	-0.29	-0.52
F	0.01	-0.89	-0.99	-0.44	-0.75

Funciones discriminantes y verificación. Implementamos $\delta_k(x)$ y comparamos contra `MASS::lda()`.

```r
S_inv <- solve(Sigma_hat)
delta <- function(X) sapply(K, \(k)
  X %*% S_inv %*% mu_hat[k, ] -
    0.5 * drop(t(mu_hat[k, ]) %*% S_inv %*% mu_hat[k, ]) + log(pi_hat[[k]]))

pred_manual_te <- factor(K[max.col(delta(X_te))], levels = K)

fit <- lda(X_tr, grouping = y_tr)
pred_tr <- predict(fit, X_tr)$class
pred_te <- predict(fit, X_te)$class
coincidencia <- mean(pred_manual_te == pred_te)
```

La implementación manual coincide con `lda()` en 100 % de los estudiantes de prueba.

Cuadro 3: Coeficientes de las funciones discriminantes. Proporción de separación: LD1 = 99.1 %, LD2 = 0.5 %, LD3 = 0.4 %, LD4 = 0.1 %.

Variable	LD1	LD2	LD3	LD4
study_time_hours	-1.15	0.12	-0.61	0.13
attendance_percent	-0.53	0.74	0.50	-0.30
sleep_hours	-0.28	-0.04	0.42	0.89
previous_grade	-0.80	-0.62	0.45	-0.35

5. Resultados

```r
cm_tr <- confusionMatrix(pred_tr, y_tr)
cm_te <- confusionMatrix(pred_te, y_te)
```

Cuadro 4: Matrices de confusión (renglones: predicción; columnas: valor real).

	Entrenamiento					Prueba				
	A	B	C	D	F	A	B	C	D	F
A	131	42	6	0	0	55	25	1	0	0
B	64	153	63	8	0	29	55	31	2	0
C	4	52	107	46	6	1	26	41	22	1
D	0	1	7	9	2	0	0	5	2	2
F	0	0	0	0	1	0	0	0	0	0

La exactitud es 57.1 % en entrenamiento y 51.3 % en prueba, frente a 35.3 % de un clasificador que siempre predijera la clase más frecuente. La sensibilidad por clase en prueba (proporción de estudiantes de cada calificación que el modelo identifica correctamente) es: A 64.7 %, B 51.9 %, C 52.6 %, D 7.7 %, F 0 %. Del total de errores en prueba, 96.6 % ocurren entre calificaciones adyacentes.

6. Conclusiones

1. **Capacidad de anticipación.** Antes del examen final, LDA anticipa correctamente la calificación de 51.3 % de los estudiantes de prueba, 16 puntos porcentuales por encima de la línea base. La diferencia entre entrenamiento y prueba (5.8 puntos) sugiere cierto sobreajuste. Para fines de alerta temprana, la clase más relevante es la calificación más baja (F): el modelo detecta a 0 % de estos estudiantes.

2. **Características que distinguen las calificaciones.** La primera función discriminante concentra 99.1 % de la separación entre clases y su coeficiente de mayor magnitud corresponde a study_time_hours. Los cuatro coeficientes de LD1 tienen el mismo signo, y las medias por clase de las cuatro variables decrecen de A a F; por lo tanto, LD1 es esencialmente un eje de "desempeño general" en el que valores más negativos corresponden a mejores calificaciones. Como las variables están estandarizadas, los pesos son comparables: las horas de estudio pesan más (-1.15), seguidas de la calificación previa (-0.8), la asistencia (-0.53) y las horas de sueño (-0.28). Es decir, los hábitos en conjunto aportan más a la separación que la calificación previa, aunque esta sigue siendo el segundo predictor individual. Como las demás funciones discriminantes aportan muy poca separación, la clasificación depende casi por completo de este único eje.
3. **Gravedad de los errores.** La mayoría de los errores ocurren entre calificaciones adyacentes (por ejemplo, B en lugar de C), lo que indica que LD1 ordena a los estudiantes de manera coherente con la escala de calificaciones y que, cuando el modelo se equivoca, el error suele ser moderado.

Limitaciones. Los datos son sintéticos; las variables categóricas quedan fuera del modelo; y el supuesto de covarianza común no se verificó formalmente.

Replicación. R con `tidyverse`, `janitor`, `MASS`, `caret` y `kableExtra`; semilla 2026; partición estratificada 70/30 con `createDataPartition`; estandarización con parámetros de entrenamiento.