Reporte 2: Perfiles metabólicos de pacientes mediante clustering jerárquico

Saúl Ubaldo Rojas Vázquez

06/10/2026

1. Introducción

El conjunto *Diabetes Risk Prediction* (Kaggle) contiene 50000 pacientes y 42 variables: antropometría, biomarcadores (glucosa, HbA1c, insulina, lípidos, presión arterial), estilo de vida, antecedentes clínicos y el puntaje y la categoría de riesgo de diabetes. Sin usar la etiqueta de riesgo, aplicamos clustering jerárquico para responder: (1) ¿existen perfiles metabólicos diferenciados y cuántos sugieren los datos?; (2) ¿qué biomarcadores los distinguen?; y (3) ¿coinciden con la categoría de riesgo?

2. Datos

Hay 0 registros duplicados (buscados ignorando `patient_id`) y faltantes en `age` (1 %), `height_cm` (5.9 %), `weight_kg` (5.9 %), `blood_glucose` (1.9 %), `hb_a1c` (3.9 %), `total_cholesterol` (2 %), `hdl` (2 %), `ldl` (2 %), `triglycerides` (2 %), `physical_activity_level` (1 %), `exercise_hours_per_week` (4 %), `daily_walking_minutes` (3.9 %), `sleep_hours` (4 %), `medication_adherence` (2 %), que imputamos con la mediana. La categoría de riesgo se distribuye como Low 0.9 %, Moderate 25.9 %, High 73.2 %. Las variables categóricas (género, hipertensión, antecedentes familiares, tabaquismo) tienen proporciones casi exactamente uniformes, la mediana de las correlaciones absolutas entre los 12 biomarcadores es 0.003 y la correlación entre glucosa y HbA1c, que en pacientes reales es alta, es 0.001. Todo ello indica que el conjunto es **sintético**, con variables generadas de forma independiente, lo que anticipa poca estructura de grupos.

3. Metodología

El clustering jerárquico aglomerativo parte de cada paciente como un grupo y, en cada paso, fusiona los dos grupos más cercanos. El resultado es un **dendrograma**, cuya altura de fusión indica qué tan distintos eran los grupos al unirse. Usamos distancia euclidiana y comparamos cuatro **enlaces** (distancia entre grupos A y B): **simple**, $\min_{a,b} d(a,b)$, que tiende a encadenar; **completo**, $\max_{a,b} d(a,b)$, que produce grupos compactos; **promedio**, $\frac{1}{|A||B|}\sum_{a,b} d(a,b)$; y **Ward**, que fusiona el par que menos aumenta $W = \sum_k \sum_{i \in C_k} \|x_i - \mu_k\|^2$. Tras fusionar i y j, la distancia a cada grupo k se actualiza con la fórmula de Lance–Williams, $d(k, i \cup j) = \alpha_i d_{ki} + \alpha_j d_{kj} + \beta d_{ij} + \gamma |d_{ki} - d_{kj}|$, cuyos coeficientes definen el enlace. El método no exige fijar el número de grupos: este se **sugiere** buscando un salto grande en las alturas de fusión, y si los distintos enlaces coinciden la estructura es más creíble.

Decisiones. (i) Usamos los 12 biomarcadores numéricos (omitimos estatura, peso y colesterol total por redundantes, y las categóricas porque no admiten distancia euclidiana). (ii) El puntaje y la categoría de

riesgo solo se usan para validar. (iii) Estandarizamos con media y desviación de entrenamiento. (iv) Como el método requiere la matriz completa de distancias ($O(n^2)$ en memoria), construimos los dendrogramas con una muestra aleatoria de 2,000 pacientes (semilla 2026) y asignamos el resto (prueba) al centroide más cercano para evaluar si los grupos se generalizan.

4. Implementación

Implementamos el algoritmo aglomerativo con Lance–Williams; para Ward se trabaja con distancias al cuadrado, como `hclust(method = "ward.D2")`.

```
aglomerativo <- function(d, enlace) {
  D <- as.matrix(d); if (enlace == "ward") D <- D^2
  diag(D) <- Inf
  tam <- rep(1, nrow(D)); activo <- rep(TRUE, nrow(D)); alturas <- c()
  for (paso in seq_len(nrow(D) - 1)) {
    Dm <- D; Dm[!activo, ] <- Inf; Dm[, !activo] <- Inf
    ij <- which(Dm == min(Dm), arr.ind = TRUE)[1, ]       # par más cercano
    i <- ij[1]; j <- ij[2]; h <- D[i, j]
    alturas <- c(alturas, if (enlace == "ward") sqrt(h) else h)
    ni <- tam[i]; nj <- tam[j]; nk <- tam
    nueva <- switch(enlace,                                # Lance-Williams
      single   = pmin(D[i, ], D[j, ]),
      complete = pmax(D[i, ], D[j, ]),
      average  = (ni * D[i, ] + nj * D[j, ]) / (ni + nj),
      ward     = ((ni + nk) * D[i, ] + (nj + nk) * D[j, ] - nk * h) /
                 (ni + nj + nk))
    D[i, ] <- nueva; D[, i] <- nueva; D[i, i] <- Inf
    activo[j] <- FALSE; tam[i] <- ni + nj
  }
  alturas
}
```

En una submuestra de 200 pacientes, las alturas de fusión de nuestra implementación coinciden con las de `hclust()` en 4 de los 4 enlaces. Por eficiencia, los dendrogramas con los 2,000 pacientes se calculan con `hclust()`.

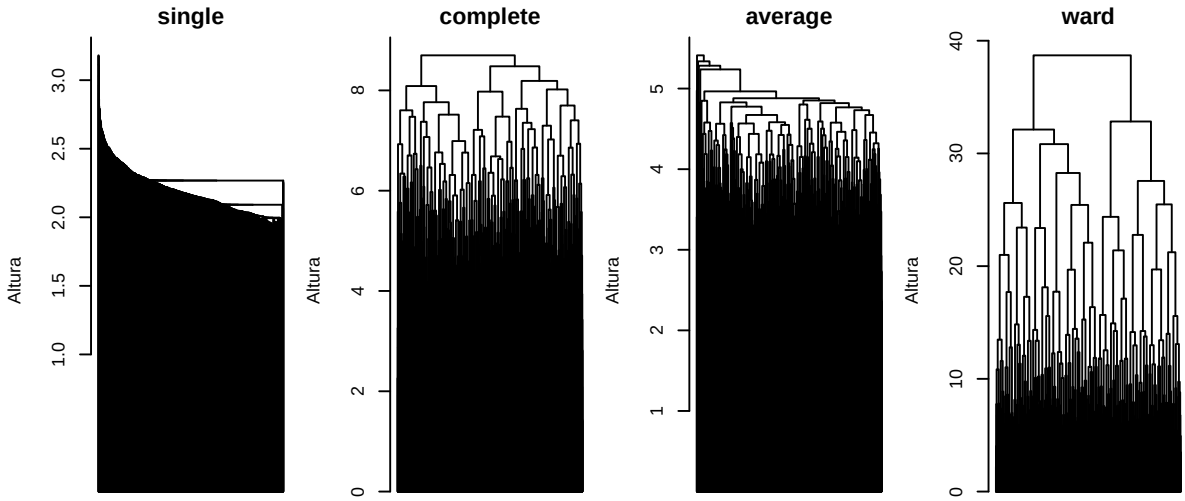


Figura 1: Dendrogramas de los 2,000 pacientes de entrenamiento según el tipo de enlace.

Cuadro 1: Altura de la fusión que reduce el número de grupos de k a k - 1.

	k = 2	k = 3	k = 4	k = 5	k = 6	k = 7	k = 8
single	3.18	3.11	3.03	2.96	2.90	2.86	2.81
complete	8.70	8.48	8.19	8.09	8.02	7.98	7.76
average	5.41	5.34	5.28	5.24	4.97	4.97	4.88
ward	38.70	32.83	32.12	30.83	28.26	27.56	25.61

Elección del número de grupos. Un salto grande entre las alturas de $k+1$ y k grupos indica que hubo que unir grupos muy distintos, por lo que conviene cortar antes. En los enlaces simple, completo y promedio las alturas descienden de forma casi continua, sin un salto que destaque. En Ward, el mayor salto ocurre de 3 a 2 grupos (de 32.83 a 38.70), mientras que de 4 a 3 la altura apenas cambia (32.12 a 32.83); por ello elegimos $k = 3$, aunque incluso este salto es modesto. Al cortar en $k = 3$, los tamaños de grupo son 1998/1/1 (simple), 1983/13/4 (promedio), 792/735/473 (completo) y 1103/561/336 (Ward): simple y promedio solo aíslan unos cuantos pacientes, efecto del encadenamiento. Adoptamos **Ward** para la partición final porque produce grupos compactos de tamaño comparable y su criterio es coherente con describir cada grupo por su centroide.

5. Resultados

Reetiquetamos los grupos de Ward en orden creciente de HbA1c y asignamos cada paciente de prueba al centroide más cercano.

Cuadro 2: Centroides en unidades originales y perfil de los grupos (entrenamiento).

	Grupo 1	Grupo 2	Grupo 3
age	51.68	53.78	55.26
bmi	30.35	29.20	32.03
waist_circumference_cm	95.39	102.08	101.84
blood_glucose	152.93	166.28	164.45
hb_a1c	7.94	8.54	8.74
fasting_blood_sugar	130.64	166.33	140.66
insulin_level	18.33	14.60	28.76
blood_pressure_systolic	150.75	146.35	131.76
blood_pressure_diastolic	95.39	90.18	88.33
hdl	60.82	57.40	57.62
ldl	123.35	152.80	132.60
triglycerides	270.60	171.01	227.13
n (entrenamiento)	561.00	336.00	1103.00
% hipertensión	49.02	52.98	51.68
% antecedentes familiares	46.88	50.89	50.95
Puntaje de riesgo medio	72.34	79.14	75.00

Cuadro 3: Distribución (%) de la categoría de riesgo dentro de cada grupo.

	Entrenamiento			Prueba		
	Low	Moderate	High	Low	Moderate	High
Grupo 1	1.1	30.8	68.1	1.7	33.1	65.1
Grupo 2	0.9	16.1	83.0	0.3	17.3	82.4
Grupo 3	1.3	22.0	76.7	0.8	26.2	73.0

6. Conclusiones

1. **Estructura de grupos.** Los dendrogramas sugieren 3 grupos, pero la evidencia es débil: solo Ward muestra un salto apreciable, los demás enlaces no lo reproducen y la suma de cuadrados dentro de los grupos por paciente (11.35) es apenas menor que la varianza total de las 12 variables estandarizadas (12): los grupos explican cerca de 5.4 % de la variabilidad. Son particiones del espacio de biomarcadores más que poblaciones naturales, lo cual es consistente con datos sintéticos.
2. **Biomarcadores que los distinguen.** No la glucosa ni la HbA1c (sus centroides difieren menos de 0.4 desviaciones estándar), sino insulina, triglicéridos, glucosa en ayunas, LDL y presión arterial. El grupo 1 combina triglicéridos y presión altos con insulina baja; el grupo 2, glucosa en ayunas y LDL altos con insulina y triglicéridos bajos; el grupo 3, el más numeroso, insulina alta y presión sistólica más baja. Hipertensión y antecedentes familiares rondan 50 % en los tres.
3. **Relación con el riesgo.** El puntaje medio por grupo es 72.3, 79.1, 75 y, en prueba, la proporción en la categoría de mayor riesgo va de 65.1 % a 82.4 %. El grupo 2 la concentra más, posiblemente por su glucosa en ayunas elevada, pero el riesgo alto es mayoritario en los tres grupos: los perfiles se asocian con el riesgo sin reproducirlo.
4. **Generalización.** La suma de cuadrados por paciente es similar en entrenamiento y prueba (11.35 frente a 11.03), pero las proporciones por grupo cambian (el grupo 3 pasa de 55.1 % a 42.7 % y el grupo 2 de 16.8 % a 26.6 %): la asignación al centroide más cercano no reproduce las fronteras de Ward, otra señal de límites poco definidos.

Limitaciones y replicación. Datos sintéticos; dendrogramas con una submuestra; variables categóricas excluidas; elección subjetiva de k. R con `tidyverse`, `janitor` y `kableExtra`, semilla 2026.